



University of
Applied Sciences
St. Pölten

Orchestrierung von Large Language Models im Kontext von Energiegemeinschaften

SUBTITLE

Bachelorarbeit

Angestrebter akademischer Grad

Bachelor of Science (BSc)

eingereicht von

David Schwarz

52308568

im Rahmen des
Studienganges Data Science and Business Analytics an der Hochschule für Angewandten
Wissenschaften St. Pölten

Betreuung

Betreuer/in: FH-Prof. Dipl.-Wirt.-Inf. Dr. Torsten Priebe

Kurzfassung

Enthält:

- Motivation,
- Problemstellung,
- Ergebnisse
- (Inhalt siehe englische Version)

Inhaltsverzeichnis

1. Einleitung	7
1.1. Problemfeld	7
1.2. Forschungsproblem	7
1.3. Forschungsfrage	8
1.4. Ziel der Arbeit	8
1.5. Hypothese	8
1.6. Methodisches Vorgehen	8
2. Grundlagen	9
2.1. Large Language Models	9
2.2. Tool-Augmented LLMs	9
2.3. Tool-Orchestrierung	9
2.4. Energiegemeinschaften	9
3. Stand der Forschung	11
3.1. Tool-Use Ansätze	11
3.2. Tool Auswahl	11
4. Methodik (4-6 Seiten)	13
4.1. Forschungsdesign	13
4.2. Literaturrecherche	13
4.3. Tooldesign	13
4.4. Testdaten	15
4.5. Orchestrierungsstrategien	16
4.6. Bewertungskriterien	16
4.7. Versuchsablauf	16
5. Ergebnisse	17
6. Diskussion	19
7. Fazit	21
7.1. Weiterführende Arbeiten	21
Akronyme	23
Abbildungsverzeichnis	25
Tabellenverzeichnis	27
Source Code Verzeichnis	29
Literaturverzeichnis	31

1. Einleitung

1.1. Problemfeld

Large Language Models (LLMs) werden immer häufiger eingesetzt, um auch komplexe Informationsanfragen zu beantworten [1], [2]. Durch Integration von externen Werkzeugen können Sprachmodelle beispielsweise auf Datenbanken zugreifen oder Berechnungen durchführen [2], [3], [4]. Die Entscheidungslogik (Orchestrierung) bestimmt, welche Tools wann und in welcher Reihenfolge aufgerufen werden [5], [6].

Energiegemeinschaften sind Zusammenschlüsse von Teilnehmenden die Privatpersonen, Gemeinden oder Unternehmen sein können. Diese verwalten gemeinsam die Produktion, Speicherung und Nutzung von Energie, um diese effizient zu nutzen [7], [8]. In diesem Kontext können Anfragen darin bestehen Analysen von Energiedaten oder Prognosen zu erstellen oder bei Entscheidungsfragen zu unterstützen.

Dabei gibt es eine entscheidende Herausforderung. Die Orchestrierung kann unterschiedlich stark autonomisiert sein. Das bedeutet wie viel Entscheidungsspielraum das LLM bei der Toolauswahl selbst hat und wie viel durch feste Regeln vorgegeben wird. Einfache deterministische Ansätze ermöglichen eine hohe Kontrolle. Autonomere Ansätze können flexibler auf komplexe Anfragen reagieren, sind dagegen schwerer vorhersehbar [9], [4], [6], [10].

1.2. Forschungsproblem

Mit zunehmendem Autonomiegrad können LLMs selbst entscheiden, welche Tools wann und in welcher Reihenfolge aufgerufen werden. Dies kann zwar komplexere Anfragen abdecken, aber auch zu ineffizienten Toolaufrufen führen und ist weniger kontrollierbar.

Ineffizient wäre es zum Beispiel, wenn das LLM entscheidet die selben Daten mehrfach abzufragen oder andere unnötige Toolaufrufe zu machen die für die Antwort keinen Mehrwert bieten. Das führt zu höherem Ressourcenverbrauch und damit auch höhere Wartezeit und höhere Kosten als notwendig wäre. Im schlechtesten Fall können auch falsche Toolaufrufe gewählt werden die falsche oder unpräzise Antworten zur Folge haben können. Bei Häufung dieser Fälle gilt es zu überlegen ob man auf eine weniger autonome Orchestrierungsmethode setzt, um Effizienz und Kontrollierbarkeit zu gewährleisten [6].

Kontrollierbarkeit ist deshalb wichtig, weil davon die Richtigkeit der Daten abhängen kann und es nicht trivial ist wer wann welche Informationen erhält, wie sie aufbereitet werden und welche Handlungsempfehlungen daraus abgeleitet werden oder welche konkret durch das LLM gegeben werden. Was den Teilnehmenden empfohlen wird kann deren Entscheidungen beeinflussen und dadurch starken Einfluss auf die jeweilige Energiegemeinschaft haben. Falsche Empfehlungen können dazu führen, dass der Verbrauch nicht sinnvoll an die verfügbare Energie angepasst wird. Und selbst wenn

die Empfehlung korrekt ist, aber deshalb jeder zum gleichen Zeitpunkt hohe Verbraucher einschaltet kann das in Summe wieder zu schlechter Ausnutzung der verfügbaren Energie führen.

1.3. Forschungsfrage

Wie beeinflusst der Grad an Autonomie in der Orchestrierung von Large Language Models die Qualität der Toolauswahl, Effizienz der Systemausführung und Kontrollierbarkeit des Systems im Kontext von Energiegemeinschaften?

1.4. Ziel der Arbeit

Ziel dieser Arbeit ist es, den Einfluss des Autonomiegrades in der Orchestrierung von Large Language Models auf Effizienz, Toolauswahl und Kontrollierbarkeit systematisch zu untersuchen und daraus eine Entscheidungsgrundlage für geeignete Orchestrierungsstrategien im Kontext von Energiegemeinschaften zu bieten.

1.5. Hypothese

Die Annahme ist, dass Orchestrierungsstrategien mit höherer Autonomie komplexere Anfragen flexibler verarbeiten können, jedoch zu geringerer Kontrollierbarkeit, höheren Ausführungskosten sowie höheren Laufzeiten führt.

1.6. Methodisches Vorgehen

Diese Arbeit verfolgt einen analytischen und vergleichenden Forschungsansatz. Zunächst wird eine strukturierte Literaturrecherche durchgeführt, um den aktuellen Stand der Forschung zu bestehenden Orchestrierungsstrategien für LLM-Systeme zu ermitteln. Basierend darauf werden exemplarische Ansätze mit unterschiedlichen Autonomiegraden ausgewählt und systematisch analysiert.

Für den Vergleich werden Bewertungskriterien definiert, die sich an theoretischen Überlegungen und spezifischen Anforderungen des Anwendungsfeldes von Energiegemeinschaften orientieren. Anschließend folgt ein strukturierter Vergleich der gewählten Ansätze anhand dieser Kriterien sowie exemplarischer Anwendungsszenarien. Ziel ist es Stärken, Schwächen und Grenzen transparent herauszuarbeiten.

2. Grundlagen

- 4-5 Seiten

2.1. Large Language Models

2.2. Tool-Augmented LLMs

2.3. Tool-Orchestrierunhg

2.4. Energiegemeinschaften

[\[1\]](#), [\[2\]](#), [\[3\]](#), [\[4\]](#), [\[11\]](#)

3. Stand der Forschung

- 7-10 Seiten

3.1. Tool-Use Ansätze

[\[1\]](#), [\[2\]](#), [\[4\]](#)

3.2. Tool Auswahl

[\[5\]](#), [\[6\]](#)

- wie Autonomie untersucht wird
- welche Benchmarks existieren

4. Methodik (4-6 Seiten)

4.1. Forschungsdesign

- vergleichende Studie
- kontrollierte Experimente
- gleiche Testbedingungen
- synthetische Daten
- Fokus auf Reproduzierbarkeit

Sämtliche Voruntersuchungen sowie die anschließende Evaluation wurden mit den Modellen GPT-5.4 und GPT-5.4-mini durchgeführt. Sofern nicht anders angegeben, beziehen sich alle im Folgenden beschriebenen Beobachtungen und Designentscheidungen auf diese Modelle.

4.2. Literaturrecherche

Anfangs wurde eine strukturierte Literaturrecherche durchgeführt. Hierfür wurden die Datenbanken Google Scholar und IEEE verwendet. Als Suchbegriffe wurden verschiedene Konstellationen von „large language model“, „Large language models“, „tool“, „tools“ und „use“ verwendet. Es wurde jeweils nach Ergebnissen nach 2022 gefiltert.

In Google Scholar wurde am 05.03.2026 mit folgendem Suchbegriff gesucht: „allintitle: (tool OR tools) use („large language model“ OR „large language models“)“ und ergab 64 Treffer.

In IEEE wurde am 10.03.2026 mit folgendem Suchbegriff gesucht: „(„Document Title“:large language model) AND („Document Title“:tool) AND („All Metadata“:use)“ und ergab 37 Treffer.

Nach einem groben Überblick über Titel und Zusammenfassungen und anschließender detaillierten Prüfung der Inhalte wurden 17 Publikationen ausgewählt, die sich direkt mit Tool Use, Tool Selection oder Orchestrierung von Large Language Models beschäftigen. Diese dienten als Grundlage für die Recherche.

4.3. Tooldesign

- tools gpt api nicht genommen um Vergleichbarkeit mit anderen Modellen zu gewährleisten (Architektur wäre unklar, nicht nur gpt testen sondern Strategie)

Zielsetzung Werkzeuge Parameter

4.3.1. Zeitauflösung

Zeitangaben in Benutzeranfragen müssen vor einem Toolaufruf eindeutig in konkrete Zeitintervalle überführt werden. Da Anfragen sowohl relative als auch komplex formulierte Zeitangaben enthalten

können und sich diese auf unterschiedliche zeitliche Granularitäten beispielsweise Tage oder Stunden beziehen, stellt die zuverlässige Parametrisierung der Werkzeuge eine grundlegende Voraussetzung für eine reproduzierbare Evaluation dar.

Im System werden Zeitintervalle durch einen Start- und Endzeitpunkt im Format [start, end) beschrieben, wobei der Startzeitpunkt inkludiert und der Endzeitpunkt exkludiert ist. Ein einzelner Kalendertag wird daher durch den Beginn dieses Tages sowie den Beginn des Folgetages beschrieben.

Für die Zeitauflösung wurden zwei Ansätze betrachtet: die Verwendung eines dedizierten Werkzeugs zur Interpretation natürlicher Zeitangaben sowie die direkte Parametrisierung durch das LLM. Zur Bewertung beider Ansätze wurde eine Voruntersuchung mit aktuellen Sprachmodellen durchgeführt. Hierbei wurden repräsentative Anfragen mit relativen und komplexen Zeitangaben formuliert und die erzeugten Toolparameter analysiert.

Die Untersuchung zeigte, dass aktuelle Modelle mit geeigneten Instruktionen Zeitangaben zuverlässig in korrekte Zeitintervalle überführen können. Auf die Implementierung eines separaten Zeitauflösungswerkzeugs wurde daher verzichtet, wodurch die Komplexität der Werkzeuglandschaft reduziert werden konnte.

4.3.2. Bereitstellung und Interpretation von Zeitreihendaten

Zeitreihendaten stellen besondere Anforderungen an die Interaktion zwischen LLM und Werkzeugen. Während Energiedaten häufig aus mehreren hundert bis tausend Messwerten bestehen, sind Large Language Models primär für die Verarbeitung natürlicher Sprache optimiert. Die direkte Übergabe vollständiger Zeitreihen als JSON oder Array erhöht den Tokenverbrauch erheblich und erschwert gleichzeitig die Identifikation relevanter Muster innerhalb langer Zahlenfolgen.

Grundsätzlich bestehen zwei Möglichkeiten, Zeitreihendaten für ein LLM bereitzustellen. Der erste Ansatz besteht darin, die Rohdaten direkt als strukturierte Werte zu übergeben und die Interpretation vollständig dem Sprachmodell zu überlassen. Alternativ können Zeitreihen vor der Übergabe aufbereitet werden, beispielsweise durch externe Analysewerkzeuge oder durch eine visuelle Darstellung in Form von Diagrammen. In der Literatur konnte bereits gezeigt werden, dass insbesondere Visualisierungen die Verarbeitung von Zeitreihen durch LLMs verbessern und gleichzeitig den Tokenverbrauch deutlich reduzieren können.

Zur Bewertung dieser Ansätze wurde eine Voruntersuchung im Kontext synthetischer Energiedaten durchgeführt. Hierbei wurden Zeitreihen unterschiedlicher Länge sowohl als strukturierte JSON-Daten als auch als Liniendiagramme an das Modell übergeben und hinsichtlich Antwortqualität, Tokenverbrauch und Bearbeitungszeit verglichen. Zusätzlich wurde untersucht, inwieweit mehrere Zeitreihen gleichzeitig verarbeitet werden können.

Die Ergebnisse zeigten, dass beide Darstellungsformen eine korrekte Interpretation einfacher Verbrauchsmuster ermöglichen. Mit zunehmender Länge der Zeitreihen erwiesen sich Visualisierungen jedoch als deutlich effizienter hinsichtlich Tokenverbrauch und Bearbeitungszeit. Gleichzeitig zeigte sich, dass die eigentliche Mustererkennung nicht zwangsläufig durch das LLM erfolgen muss. Wiederkehrende Analysen, wie beispielsweise die Erkennung von Lastspitzen oder die Berechnung statistischer Kennwerte, können konsistenter und ressourcenschonender durch spezialisierte Analysewerkzeuge durchgeführt werden.

Auf Basis dieser Erkenntnisse wurde das Tooldesign so gewählt, dass das LLM Zeitreihen nicht grundsätzlich selbst interpretieren muss. Stattdessen stellen Werkzeuge je nach Anwendungsfall entweder aufbereitete Visualisierungen oder bereits analysierte Informationen bereit. Das LLM übernimmt

damit primär die Orchestrierung sowie die sprachliche Interpretation der Ergebnisse, während rechenintensive oder wiederkehrende Zeitreihenanalysen an spezialisierte Werkzeuge ausgelagert werden.

4.4. Testdaten

4.4.1. Szenarien

4.4.2. Datengenerierung

- ausgehend von einer Energiegemeinschaft
- Testdaten: 01.01.2026 - 31.03.2026 (inklusive)
- Referencetime: 02.04.2026

meters.csv

- meter_id
- meter_name (meist nur bei vielen Zählpunkten vorhanden)
- user_id
- direction
- location
- note

timeseries.csv (15min)

- meter_id
- timestamp
- value
- unit

forecast.csv (1h)

- timestamp
- generation
- consumption

spotmarket.csv (1h)

- timestamp
- value (kann auch negativ sein)

Characteristics

- normal: actual bis gestern 0 Uhr danach forecast
- missing values: forecast über längeren Zeitraum (llm soll auf prognostizierte Werte aufmerksam machen)
- missing values: auch kein forecast
- missing values: vereinzelte actuals (llm soll auf fehlende Werte aufmerksam machen)

4.4.3. Referenzzeit

Es wurde die Verwendung dynamisch generierter Testdaten untersucht. Da relative Zeitangaben abhängig vom tatsächlichen Ausführungszeitpunkt unterschiedliche Ergebnisse liefern würden, wurde stattdessen ein fester Testdatensatz mit einer vollständig definierten Referenzzeit verwendet. Diese umfasst neben dem Datum auch die Uhrzeit sowie die zugehörige Zeitzone und wird vom LLM als aktueller Zeitpunkt interpretiert. Dadurch können neben tagesbasierten auch stundenbasierte Zeitangaben, beispielsweise „vor drei Stunden“ oder „seit heute Morgen“, eindeutig aufgelöst werden.

Gleichzeitig wird sichergestellt, dass identische Anfragen unabhängig vom tatsächlichen Zeitpunkt der Versuchsdurchführung stets zu denselben Zeitintervallen und damit zu identischen Toolparametern führen.

Diese Entscheidungen stellen sicher, dass Unterschiede zwischen den Orchestrierungsmethoden nicht durch die Verarbeitung natürlicher Zeitangaben beeinflusst werden und die Evaluation reproduzierbar durchgeführt werden kann.

4.5. Orchestrierungsstrategien

4.6. Bewertungskriterien

- Tool Selection Accuracy
- unnötige/redundante Toolaufrufe
- Schrittzahl
- Antwortqualität
- Laufzeit
- Tokenverbrauch

4.7. Versuchsablauf

- Eine Testanfrage wird ausgewählt.
- Eine Orchestrierungsmethode wird gestartet.
- Das LLM ruft Tools auf.
- Die Tool-Rückgaben werden verarbeitet.
- Die finale Antwort wird erzeugt.
- Die Bewertungskriterien werden berechnet.
- Der Vorgang wird für alle Methoden wiederholt.

5. Ergebnisse

- 4-6 Seiten
- Tabellen
- Beobachtungen

6. Diskussion

- 3-4 Seiten
- wann welche Strategie sinnvoll ist
- Auswirkungen auf Energiegemeinschaften
- Limitationen

7. Fazit

- 2 Seiten

7.1. Weiterführende Arbeiten

Examine the limitations inherent in your work and outline potential avenues for future research and development.

Akronyme

Abbildungsverzeichnis

Tabellenverzeichnis

Source Code Verzeichnis

Literaturverzeichnis

- [1] B. Paranjape, S. Lundberg, S. Singh, H. Hajishirzi, L. Zettlemoyer, und M. T. Ribeiro, „ART: Automatic Multi-Step Reasoning and Tool-Use for Large Language Models“. 2023.
- [2] R. Yang u. a., „GPT4Tools: Teaching Large Language Model to Use Tools via Self-instruction“, in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, und S. Levine, Hrsg., Curran Associates, Inc., 2023, S. 71995–72007.
- [3] Z. Duan und J. Wang, „Multi-Tool Integration Application for Math Reasoning Using Large Language Model“, in *2024 IEEE 10th International Conference on Edge Computing and Scalable Cloud (EdgeCom)*, 2024, S. 106–109. doi: 10.1109/EdgeCom62867.2024.00024.
- [4] L. Alazraki und M. Rei, „Meta-Reasoning Improves Tool Use in Large Language Models“, in *Findings of the Association for Computational Linguistics: NAACL 2025*, L. Chiruzzo, A. Ritter, und L. Wang, Hrsg., Albuquerque, New Mexico: Association for Computational Linguistics, Apr. 2025, S. 7900–7912. doi: 10.18653/v1/2025.findings-naacl.440.
- [5] Y. Huang u. a., „MetaTool Benchmark for Large Language Models: Deciding Whether to Use Tools and Which to Use“. 2024.
- [6] J. Liu, K. Ning, Y. Su, W. Han, J. Xu, und Y. Zhang, „WTU-EVAL: A Whether-or-Not Tool Usage Evaluation Benchmark for Large Language Models“, in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2025, S. 1–5. doi: 10.1109/ICASSP49660.2025.10889153.
- [7] N. K. A. GmbH, „Was Sind Energiegemeinschaften Und Wie Funktionieren Sie?“.
- [8] Ö. K. für Energiegemeinschaften, „Rechtsgrundlagen Für Energiegemeinschaften“.
- [9] Y. Zhang u. a., „Geospatial Large Language Model Trained with a Simulated Environment for Generating Tool-Use Chains Autonomously“, *International Journal of Applied Earth Observation and Geoinformation*, Bd. 136, S. 104312, 2025, doi: 10.1016/j.jag.2024.104312.
- [10] Z.-Y. Chen, S. Shen, G. Shen, G. Zhi, X. Chen, und Y. Lin, „Towards Tool Use Alignment of Large Language Models“, in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, und Y.-N. Chen, Hrsg., Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, S. 1382–1400. doi: 10.18653/v1/2024.emnlp-main.82.
- [11] Y. Chen u. a., „Fortify the Shortest Stave in Attention: Enhancing Context Awareness of Large Language Models for Effective Tool Use“, in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2024, S. 11160–11174.

