



University of
Applied Sciences
St. Pölten

Orchestrierung von Large Language Models im Kontext von Energiegemeinschaften

SUBTITLE

Bachelorarbeit

Angestrebter akademischer Grad

Bachelor of Science (BSc)

eingereicht von

David Schwarz

52308568

im Rahmen des
Studienganges Data Science and Business Analytics an der Hochschule für Angewandten
Wissenschaften St. Pölten

Betreuung

Betreuer/in: FH-Prof. Dipl.-Wirt.-Inf. Dr. Torsten Priebe

Kurzfassung

Enthält:

- Motivation,
- Problemstellung,
- Ergebnisse
- (Inhalt siehe englische Version)

Inhaltsverzeichnis

1. Einleitung	7
1.1. Problemfeld	7
1.2. Forschungsproblem	7
1.3. Forschungsfrage	8
1.4. Ziel der Arbeit	8
1.5. Hypothese	8
1.6. Methodisches Vorgehen	8
2. Grundlagen	9
2.1. Large Language Models	9
2.2. Tool-Augmented LLMs	9
2.3. Tool-Orchestrierung	9
2.4. Energiegemeinschaften	9
3. Stand der Forschung	11
3.1. Tool-Use Ansätze	11
3.2. Tool Auswahl	11
4. Methodik	13
4.1. Literaturrecherche	13
4.2. Testdaten	15
4.3. Orchestrierungsstrategien	16
4.4. Bewertungskriterien	16
5. Herangehensweise	17
6. Ergebnisse	19
7. Diskussion	21
8. Fazit	23
8.1. Weiterführende Arbeiten	23
Akronyme	25
Abbildungsverzeichnis	27
Tabellenverzeichnis	29
Source Code Verzeichnis	31
Literaturverzeichnis	33

1. Einleitung

1.1. Problemfeld

Large Language Models (LLMs) werden immer häufiger eingesetzt, um auch komplexe Informationsanfragen zu beantworten [1], [2]. Durch Integration von externen Werkzeugen können Sprachmodelle beispielsweise auf Datenbanken zugreifen oder Berechnungen durchführen [2], [3], [4]. Die Entscheidungslogik (Orchestrierung) bestimmt, welche Tools wann und in welcher Reihenfolge aufgerufen werden [5], [6].

Energiegemeinschaften sind Zusammenschlüsse von Teilnehmenden die Privatpersonen, Gemeinden oder Unternehmen sein können. Diese verwalten gemeinsam die Produktion, Speicherung und Nutzung von Energie, um diese effizient zu nutzen [7], [8]. In diesem Kontext können Anfragen darin bestehen Analysen von Energiedaten oder Prognosen zu erstellen oder bei Entscheidungsfragen zu unterstützen.

Dabei gibt es eine entscheidende Herausforderung. Die Orchestrierung kann unterschiedlich stark autonomisiert sein. Das bedeutet wie viel Entscheidungsspielraum das LLM bei der Toolauswahl selbst hat und wie viel durch feste Regeln vorgegeben wird. Einfache deterministische Ansätze ermöglichen eine hohe Kontrolle. Autonomere Ansätze können flexibler auf komplexe Anfragen reagieren, sind dagegen schwerer vorhersehbar [4], [6], [9], [10].

1.2. Forschungsproblem

Mit zunehmendem Autonomiegrad können LLMs selbst entscheiden, welche Tools wann und in welcher Reihenfolge aufgerufen werden. Dies kann zwar komplexere Anfragen abdecken, aber auch zu ineffizienten Toolaufrufen führen und ist weniger kontrollierbar.

Ineffizient wäre es zum Beispiel, wenn das LLM entscheidet die selben Daten mehrfach abzufragen oder andere unnötige Toolaufrufe zu machen die für die Antwort keinen Mehrwert bieten. Das führt zu höherem Ressourcenverbrauch und damit auch höhere Wartezeit und höhere Kosten als notwendig wäre. Im schlechtesten Fall können auch falsche Toolaufrufe gewählt werden die falsche oder unpräzise Antworten zur Folge haben können. Bei Häufung dieser Fälle gilt es zu überlegen ob man auf eine weniger autonome Orchestrierungsmethode setzt, um Effizienz und Kontrollierbarkeit zu gewährleisten [6].

Kontrollierbarkeit ist deshalb wichtig, weil davon die Richtigkeit der Daten abhängen kann und es nicht trivial ist wer wann welche Informationen erhält, wie sie aufbereitet werden und welche Handlungsempfehlungen daraus abgeleitet werden oder welche konkret durch das LLM gegeben werden. Was den Teilnehmenden empfohlen wird kann deren Entscheidungen beeinflussen und dadurch starken Einfluss auf die jeweilige Energiegemeinschaft haben. Falsche Empfehlungen können dazu führen, dass der Verbrauch nicht sinnvoll an die verfügbare Energie angepasst wird. Und selbst wenn

die Empfehlung korrekt ist, aber deshalb jeder zum gleichen Zeitpunkt hohe Verbraucher einschaltet kann das in Summe wieder zu schlechter Ausnutzung der verfügbaren Energie führen.

1.3. Forschungsfrage

Wie beeinflusst der Grad an Autonomie in der Orchestrierung von Large Language Models die Qualität der Toolauswahl, Effizienz der Systemausführung und Kontrollierbarkeit des Systems im Kontext von Energiegemeinschaften?

1.4. Ziel der Arbeit

Ziel dieser Arbeit ist es, den Einfluss des Autonomiegrades in der Orchestrierung von Large Language Models auf Effizienz, Toolauswahl und Kontrollierbarkeit systematisch zu untersuchen und daraus eine Entscheidungsgrundlage für geeignete Orchestrierungsstrategien im Kontext von Energiegemeinschaften zu bieten.

1.5. Hypothese

Die Annahme ist, dass Orchestrierungsstrategien mit höherer Autonomie komplexere Anfragen flexibler verarbeiten können, jedoch zu geringerer Kontrollierbarkeit, höheren Ausführungskosten sowie höheren Laufzeiten führt.

1.6. Methodisches Vorgehen

Diese Arbeit verfolgt einen analytischen und vergleichenden Forschungsansatz. Zunächst wird eine strukturierte Literaturrecherche durchgeführt, um den aktuellen Stand der Forschung zu bestehenden Orchestrierungsstrategien für LLM-Systeme zu ermitteln. Basierend darauf werden exemplarische Ansätze mit unterschiedlichen Autonomiegraden ausgewählt und systematisch analysiert.

Für den Vergleich werden Bewertungskriterien definiert, die sich an theoretischen Überlegungen und spezifischen Anforderungen des Anwendungsfeldes von Energiegemeinschaften orientieren. Anschließend folgt ein strukturierter Vergleich der gewählten Ansätze anhand dieser Kriterien sowie exemplarischer Anwendungsszenarien. Ziel ist es Stärken, Schwächen und Grenzen transparent herauszuarbeiten.

2. Grundlagen

- 4-5 Seiten

2.1. Large Language Models

2.2. Tool-Augmented LLMs

2.3. Tool-Orchestrierung

2.4. Energiegemeinschaften

[\[1\]](#), [\[2\]](#), [\[3\]](#), [\[4\]](#), [\[11\]](#)

3. Stand der Forschung

- 7-10 Seiten

3.1. Tool-Use Ansätze

[\[1\]](#), [\[2\]](#), [\[4\]](#)

3.2. Tool Auswahl

[\[5\]](#), [\[6\]](#)

- wie Autonomie untersucht wird
- welche Benchmarks existieren

4. Methodik

- 4-6 Seiten

4.1. Literaturrecherche

Anfangs wurde eine strukturierte Literaturrecherche durchgeführt. Hierfür wurden die Datenbanken Google Scholar und IEEE verwendet. Als Suchbegriffe wurden verschiedene Konstellationen von „large language model“, „Large language models“, „tool“, „tools“ und „use“ verwendet. Es wurde jeweils nach Ergebnissen nach 2022 gefiltert.

In Google Scholar wurde am 05.03.2026 mit folgendem Suchbegriff gesucht: „allintitle: (tool OR tools) use („large language model“ OR „large language models“)“ und ergab 64 Treffer.

In IEEE wurde am 10.03.2026 mit folgendem Suchbegriff gesucht: „(„Document Title“:large language model) AND („Document Title“:tool) AND („All Metadata“:use)“ und ergab 37 Treffer.

Nach einem groben Überblick über Titel und Zusammenfassungen und anschließender detaillierten Prüfung der Inhalte wurden 17 Publikationen ausgewählt, die sich direkt mit Tool Use, Tool Selection oder Orchestrierung von Large Language Models beschäftigen.

4.1.1. Zeitauflösung (Methodik, Herangehensweise, Ergebnisse)

- Zeitreihendaten fix generieren
- Tools definieren: inkl start, excl end
- extra Tools vs nur llm (Test)

Anfragen können zeitliche Angaben wie „gestern“, „letzte Woche“ oder „vorletztes Monat“ enthalten. Auch komplexere Angaben wie „Wie ist mein Verbrauch der ersten 3 Tage der Woche vor dem 10. Januar?“ sind möglich. Diese müssen richtig interpretiert und entsprechend in Parameter aufgelöst werden, um einen korrekten Toolaufruf zu ermöglichen. Daher ist zu beachten, wie die Parameter übergeben werden müssen. Ein Datum wird automatisch auf 0 Uhr des selben Tages gesetzt. Das bedeutet das Ende der Zeitreihe ist exkludiert, also nicht enthalten. Wenn man nun die Zeitreihe eines Tages abfragen möchte ist es notwendig den darauffolgenden Tag als Ende anzugeben oder die Funktion anzupassen, dass sie beim Ende automatisch einen Tag dazurechnet.

Daher war die Idee dem LLM auch Tools für die Zeitauflösung zur Verfügung zu stellen, um die Parameterauswahl besser zu steuern und weniger fehleranfällig zu machen. Zuvor wurde erst getestet wie gut aktuelle Modelle Zeitangaben selbstständig auflösen können. Getestet wurden gpt-5.4 und gpt-5.4-mini. Ohne Erklärung waren die Toolaufrufe nicht immer korrekt. Speziell ob das Ende der Zeitreihe exklusiv oder inklusiv war konnte das LLM nicht wissen. Mit entsprechenden Instruktionen war die Zeitauflösung aber sehr zuverlässig. Auch kompliziertere Beispiele wie zuvor genannt wurden problemlos aufgelöst. Bei zweideutigen Angaben wird teilweise nachgefragt oder eine der beiden

Varianten angenommen und ausgeführt. Das lässt sich aber gut mit Promptengineering steuern. Da die Zeitauflösung nur mit den LLMs sowohl bei einfachen als auch komplexen Zeitabfragen sehr zuverlässig funktionierte habe ich mich dagegen entschieden extra Tools zu entwickeln zumal ich damit ohnehin nicht jede erdenkliche Kombination abgedeckt hätte.

Anfangs hatte ich die Testdaten bei jeder Nutzung neu erstellt. Die Daten waren immer die gleichen, aber immer von heute ausgehend zum Beispiel die letzten 3 Monate. So sollte das LLM immer mit den gleichen Daten ausgehend vom heutigen Tag arbeiten. Das Problem war nur, dass „letzte Woche“ immer etwas anderes bedeutete je nachdem welcher Wochentag gerade war und die Ergebnisse von Tests an verschiedenen Wochentagen nicht sauber vergleichbar und reproduzierbar waren. Die sauberere Lösung war es einen fixen Testdatensatz für einen bestimmten Zeitraum zu generieren der sich nicht mehr verändert und die Referenzzeit für das LLM vorzugeben und zu fixieren. Das bedeutet ich gebe dem LLM in den Systeminformationen ein fixes Datum innerhalb dieses Zeitraums an von dem es ausgehen sollte, dass dieses heute ist. Das wollte ich anfangs vermeiden, weil unklar war wie zuverlässig das ist und ob dadurch neue Komplikationen in der Zeitauflösung auftreten die nicht praxisnah sind. Die Bedenken sind, dass das LLM über die API ebenfalls weiß welcher Tag heute wirklich ist und bei viel Kontext möglicherweise die vorgegebene Referenzzeit untergehen könnte. Aber in den Tests ist auch dieser Fall nicht eingetreten und alle Berechnungen gingen zuverlässig von der vorgegebenen Referenzzeit aus.

Zusammengefasst habe ich mich gegen extra Tools für die Zeitauflösung entschieden. Die Testdaten wurden einmal für einen fixen Zeitraum generiert und dem LLM eine fixe Referenzzeit vorgegeben. So ist gewährleistet, dass der Testdatensatz nachvollziehbar und konsistent bleibt und das Vorgehen sauber und reproduzierbar ist.

4.1.2. Zeitauflösung (Methodik)

Anfragen können relative Zeitangaben wie „gestern“, „letzte Woche“ oder „vorletztes Monat“ sowie komplexere Formulierungen enthalten. Diese müssen in konkrete Zeitintervalle überführt werden, um korrekte Toolaufrufe zu ermöglichen.

Zeitintervalle werden im System im Format [start, end) definiert, wobei der Startzeitpunkt inkludiert und der Endzeitpunkt exkludiert ist. Ein Datum wird dabei automatisch auf 00:00 Uhr gesetzt. Soll ein einzelner Tag abgefragt werden, muss daher als Endzeitpunkt der darauffolgende Tag verwendet werden.

Für die Experimente wird ein fixer Testdatensatz für einen definierten Zeitraum verwendet. Um konsistente und reproduzierbare Ergebnisse zu gewährleisten, wird dem LLM eine feste Referenzzeit vorgegeben, die als „heutiges Datum“ interpretiert werden soll. Alle relativen Zeitangaben beziehen sich auf diese Referenzzeit.

Durch diese Festlegung wird sichergestellt, dass identische Anfragen unabhängig vom tatsächlichen Ausführungszeitpunkt stets zu denselben Zeitintervallen führen.

- Wochentag erwähnen
- Nicht nur Datum sondern auch Uhrzeit als jetzigen Zeitpunkt definieren um „vor 3 Stunden“ ebenfalls einzugrenzen
- alles in Methodik, nicht aufteilen, aber auch nicht zu sehr ins Detail gehen
- Am Ende von Voruntersuchungen und Desingentscheidungen: „Diese Designentscheidungen isolieren gezielt die Orchestrierungslogik von anderen Einflussfaktoren (z. B. Parsing von Zeitangaben), um eine vergleichbare Evaluation zu ermöglichen.“

4.1.3. Zeitauflösung (Herangehensweise)

Zunächst wurde untersucht, inwieweit aktuelle LLMs relative Zeitangaben selbstständig auflösen können. Dabei zeigte sich, dass mit geeigneten Instruktionen sowohl einfache als auch komplexe Zeitangaben zuverlässig in konkrete Zeitintervalle überführt werden können.

Auf Basis dieser Ergebnisse wurde auf die Implementierung eines separaten Tools zur Zeitauflösung verzichtet, um die Systemkomplexität zu reduzieren.

4.1.4. Zeitreihendaten interpretieren

- plot vs json

4.2. Testdaten

4.2.1. Energiedaten

- ausgehend von einer Energiegemeinschaft
- Testdaten: 01.01.2026 - 31.03.2026 (inklusive)
- Referencetime: 02.04.2026

meters.csv

- meter_id
- meter_name (meist nur bei vielen Zählpunkten vorhanden)
- user_id
- direction
- location
- note

timeseries.csv (15min)

- meter_id
- timestamp
- value
- unit

forecast.csv (1h)

- timestamp
- generation
- consumption

spotmarket.csv (1h)

- timestamp
- value (kann auch negativ sein)

Characteristics

- normal: actual bis gestern 0 Uhr danach forecast
- missing values: forecast über längeren Zeitraum (llm soll auf prognostizierte Werte aufmerksam machen)
- missing values: auch kein forecast
- missing values: vereinzelte actuals (llm soll auf fehlende Werte aufmerksam machen)

4.3. Orchestrierungsstrategien

4.4. Bewertungskriterien

5. Herangehensweise

- 6-8 Seiten
- Szenario (EGs)
- mögliche Anfragen
- Orchestrierungsstrategien

6. Ergebnisse

- 4-6 Seiten
- Tabellen
- Beobachtungen

7. Diskussion

- 3-4 Seiten
- wann welche Strategie sinnvoll ist
- Auswirkungen auf Energiegemeinschaften
- Limitationen

8. Fazit

- 2 Seiten

8.1. Weiterführende Arbeiten

Examine the limitations inherent in your work and outline potential avenues for future research and development.

Akronyme

Abbildungsverzeichnis

Tabellenverzeichnis

Source Code Verzeichnis

Literaturverzeichnis

- [1] B. Paranjape, S. Lundberg, S. Singh, H. Hajishirzi, L. Zettlemoyer, und M. T. Ribeiro, „ART: Automatic multi-step reasoning and tool-use for large language models“. [Online]. Verfügbar unter: <https://arxiv.org/abs/2303.09014>
- [2] R. Yang u. a., „GPT4Tools: Teaching Large Language Model to Use Tools via Self-instruction“, in *Advances in Neural Information Processing Systems*, A. Oh, T. Naumann, A. Globerson, K. Saenko, M. Hardt, und S. Levine, Hrsg., Curran Associates, Inc., 2023, S. 71995–72007. [Online]. Verfügbar unter: https://proceedings.neurips.cc/paper_files/paper/2023/file/e393677793767624f2821cec8bdd02f1-Paper-Conference.pdf
- [3] Z. Duan und J. Wang, „Multi-tool Integration Application for Math Reasoning Using Large Language Model“, in *2024 IEEE 10th International Conference on Edge Computing and Scalable Cloud (EdgeCom)*, 2024, S. 106–109. doi: 10.1109/EdgeCom62867.2024.00024.
- [4] L. Alazraki und M. Rei, „Meta-Reasoning Improves Tool Use in Large Language Models“, in *Findings of the Association for Computational Linguistics: NAACL 2025*, L. Chiruzzo, A. Ritter, und L. Wang, Hrsg., Albuquerque, New Mexico: Association for Computational Linguistics, Apr. 2025, S. 7900–7912. doi: 10.18653/v1/2025.findings-naacl.440.
- [5] Y. Huang u. a., „MetaTool Benchmark for Large Language Models: Deciding Whether to Use Tools and Which to Use“. [Online]. Verfügbar unter: <https://arxiv.org/abs/2310.03128>
- [6] J. Liu, K. Ning, Y. Su, W. Han, J. Xu, und Y. Zhang, „WTU-EVAL: A Whether-or-Not Tool Usage Evaluation Benchmark for Large Language Models“, in *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2025, S. 1–5. doi: 10.1109/ICASSP49660.2025.10889153.
- [7] N. K. A. GmbH, „Was sind Energiegemeinschaften und wie funktionieren sie?“. Zugegriffen: 10. März 2026. [Online]. Verfügbar unter: <https://www.next-kraftwerke.at/wissen/energiegemeinschaften>
- [8] Ö. K. für Energiegemeinschaften, „Rechtsgrundlagen für Energiegemeinschaften“. Zugegriffen: 10. März 2026. [Online]. Verfügbar unter: <https://energiegemeinschaften.gv.at/rechtsgrundlagen/>
- [9] Y. Zhang u. a., „Geospatial large language model trained with a simulated environment for generating tool-use chains autonomously“, *International Journal of Applied Earth Observation and Geoinformation*, Bd. 136, S. 104312, 2025, doi: <https://doi.org/10.1016/j.jag.2024.104312>.
- [10] Z.-Y. Chen, S. Shen, G. Shen, G. Zhi, X. Chen, und Y. Lin, „Towards Tool Use Alignment of Large Language Models“, in *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, Y. Al-Onaizan, M. Bansal, und Y.-N. Chen, Hrsg., Miami, Florida, USA: Association for Computational Linguistics, Nov. 2024, S. 1382–1400. doi: 10.18653/v1/2024.emnlp-main.82.

- [11] Y. Chen *u. a.*, „Fortify the shortest stave in attention: Enhancing context awareness of large language models for effective tool use“, in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2024, S. 11160–11174.